

Procesos del análisis y puntos que requieren revisión estadística

Auditoría de observabilidad AXA / ATUS / Fiscalía — Tamaulipas y Nuevo León, 2019–2023.
Documento para coautores. Recorre el pipeline en orden de ejecución y señala, en rojo, los pasos donde hay una decisión estadística que debe confirmarse antes del envío.

DATO paso de manejo de datos, sin decisión estadística · **REVISAR** decisión estadística que necesita confirmación · **JORGE** los tres que le tocan a Jorge por su formación en control

Resumen de los puntos a revisar

#	PASO	QUÉ HAY QUE CONFIRMAR	A QUIÉN
5	Agregación H3	Elección de resolución y si la reversión entre escalas es MAUP genuino	espacial
6	Cobertura y techo	Si el techo por oráculo es el benchmark correcto	Jorge
7	Regla de desempate	La esperanza bajo desempate aleatorio y el rango pesimista-optimista	Jorge
8	Métrica ABC	La normalización por el área hasta la diagonal aleatoria	Jorge
9	Spearman	Si el coeficiente sirve con 81–97% de empates	Jorge
10	Piso estructural	Que la capa de frecuencia excluya su propio desenlace	Jorge
11	Razón víctimas/carpeta	Su traslado (o no) de Nuevo León a Tamaulipas	Jorge
12	Captura-recaptura	Supuestos de independencia y cierre; es el más atacable	Jorge

Pipeline, en orden de ejecución

1. Extracción AXA **DATO**

→ 01_extraer_axa_tamaulipas.py · salida axa_tamaulipas_6c_2019_2023.csv

Filtra los siniestros de la aseguradora a las seis ciudades. Dos trampas ya resueltas que hay que conocer para no reintroducirlas: los archivos vienen en tres formatos distintos de CSV y el encabezado no siempre coincide con el número de columnas, así que **el campo FALLECIDO se lee por posición, nunca por nombre** (43 columnas → posiciones 22/23/24; 44 columnas → 23/24/25); y las banderas de MOTOCICLETA del final se corren un lugar entre formatos, así que la moto se identifica por TIPO VEHICULO.

2. Extracción ATUS **DATO**

→ 02_extraer_atus_tamaulipas.py · salida atus_tamaulipas_6c_2019_2023.csv

Filtra la base georreferenciada del INEGI a entidad 28 y a los seis municipios. Clave a verificar siempre: MPIO 32 es Reynosa y Ciudad Madero es 09 — confundirlas destruye las correlaciones sin dar ningún error. Cobertura irregular a documentar: Ciudad Madero no existe antes de 2021 y casi desaparece en 2023.

3. Limpieza de la Fiscalía de Tamaulipas **DATO**

→ 03_limpiar_fiscalia.py · salida fiscalia_tamaulipas_limpio.csv

766 longitudes venían sin el signo negativo y se corrigen; los registros con coordenada inválida se marcan con geo_ok en vez de borrarse. 96% de los registros resultan geolocalizables. El campo

FECHA DE INICIO es la apertura de la carpeta, no la fecha del hecho — esto no se puede arreglar y determina qué análisis son posibles (ver paso 12).

4. Polígono urbano y estratificación DATO

→ `extraer_ageb.ps1` + `07_poligono_urbano.py` · salidas `poligonos_urbanos.gpkg`, `estratos_*.csv`

Sustituye el rectángulo de coordenadas por la mancha urbana oficial: AGEB urbanas del Marco Geoestadístico 2020 disueltas por municipio, con 150 m de holgura porque las AGEB terminan al eje de la vialidad perimetral. Cada registro queda etiquetado **urbano** o **periurbano**; nada se descarta. Es una decisión metodológica, no estadística, pero conviene que alguien abra el `.gpkg` en QGIS y confirme a ojo que los polígonos corresponden a las ciudades.

5. Agregación en retícula hexagonal H3 REVISAR

→ dentro de `08_corridas_urbano.py` · resoluciones 9 (~0.12 km², escala de cuadra) y 10 (~0.017 km², escala de esquina)

Cada punto se asigna a una celda hexagonal y todo el análisis posterior corre sobre conteos por celda. La resolución cambia los resultados: a escala de esquina el indicador se degrada y en dos ciudades cruza el umbral del azar.

A confirmar: ¿la reversión entre escalas es un efecto genuino de unidad de área modificable (MAUP), o un artefacto de que a resolución 10 hay más celdas que eventos? Y si dos resoluciones bastan o hace falta una tercera para mostrar la tendencia.

6. Curva de cobertura y techo alcanzable REVISAR JORGE

→ función `curva()` en `08_corridas_urbano.py`

Se ordenan las celdas de más a menos reportes de la fuente auditada, se toma el primer tramo y se cuenta qué porcentaje del desenlace real cayó dentro: eso es la **cobertura**. El **techo** es lo mismo pero ordenando las celdas por el desenlace, o sea el máximo que alcanzaría alguien que ya supiera dónde está el daño gastando el mismo número de celdas.

A confirmar: si comparar contra un oráculo que conoce la respuesta es el benchmark correcto, o si introduce un sesgo optimista que hace ver mal a cualquier fuente por construcción.

7. Regla de desempate REVISAR JORGE

→ bloque `while` dentro de `curva()`

Entre 81% y 97% de las celdas comparten el mismo valor de frecuencia (casi todas tienen uno o dos siniestros), así que el orden *dentro* de esos bloques empatados decide buena parte de la métrica: hasta 0.20 puntos en cada dirección. Se usa la esperanza exacta bajo desempate aleatorio — en un bloque de m celdas empatadas que suman S , tomar j captura en promedio $(j/m) \cdot S$ — y se reportan las cotas pesimista y optimista.

A confirmar: que la esperanza es el estimador correcto aquí y no una simulación Monte Carlo, y si el rango pesimista-optimista debe ir en la tabla principal o en material suplementario.

8. Métrica ABC, libre de umbral REVISAR JORGE

→ función `abc()` · salida `matriz_urbano.csv`

En vez de fijar un presupuesto arbitrario, se recorre toda la curva: el área entre la curva observada y la óptima, dividida entre el área entre la óptima y la diagonal aleatoria. 0 significa que la fuente ordena tan bien como quien ya sabe la respuesta; 1 significa que ordena tan bien como escoger celdas al azar.

A confirmar: que dividir por el área hasta la diagonal es la normalización correcta, y cómo reportar los casos que pasan de 1 sin sobreafirmar que la fuente es peor que el azar en todo el rango.

9. Spearman entre capa de frecuencia y desenlace REVISAR JORGE

→ `scipy.stats.spearmanr` en `08_corridas_urbano.py`, columna `rho`

Mide si las celdas que quedan arriba en un mapa también quedan arriba en el otro. Se reporta solo como descriptivo secundario porque sufre el mismo problema del paso 7: con la mayoría de las celdas en cero, el coeficiente se calcula casi puro sobre empates.

A confirmar: si conviene otra medida de concordancia, restringir a celdas con al menos un evento, o retirarlo del manuscrito por poco informativo.

10. Piso estructural (corrida circular) REVISAR JORGE

→ salida `pisos_urbano.csv`

Separa dos explicaciones que están mezcladas: que las fuentes fallen porque son instituciones distintas, o porque contar choques no dice dónde muere la gente. Para aislarlo se hace que un solo registro se ordene contra sí mismo — las carpetas por lesiones de la Fiscalía intentando localizar sus propias carpetas por homicidio.

A confirmar, y es donde ya hubo un error: la capa de frecuencia debe **excluir** su propio desenlace. Dejar los homicidios dentro del conteo de carpetas produce 0.13 en vez de 0.60, porque la capa contiene la respuesta. Revisar que la exclusión esté bien hecha en ambos pisos y que quede declarada en Métodos.

11. Razón víctimas por carpeta REVISAR JORGE

→ derivada de la respuesta de la Fiscalía de Nuevo León

En Nuevo León hay 1,279 víctimas fatales repartidas en 1,228 carpetas de homicidio: 1.0415. Es muy estable —1.034 a 1.058 por año, 1.018 a 1.088 por municipio— porque 1,185 de las 1,228 carpetas traen una sola víctima. Para lesiones la misma razón da 1.517, mucho más variable.

A confirmar: que la razón se reporte como observación de Nuevo León y no se use para convertir carpetas en víctimas en Tamaulipas, donde esa fiscalía reservó el conteo. Ningún número de titular debe depender de ella.

12. Captura-recaptura en Nuevo León REVISAR JORGE

→ emparejamiento ATUS × Fiscalía por municipio + mismo día + hora ± 1 h

Con dos listas de las mismas muertes, el tamaño del traslape dice cuánto falta: poco traslape significa que cada lista ve una rebanada distinta y el total real es mayor. Salen 356 coincidencias; una prueba de desfase de fechas da 11.6 por azar, o sea que el emparejamiento es real. Lincoln–Petersen da al menos 1,900 eventos mortales. INEGI, por una cadena institucional independiente, cuenta 1,864 en esos mismos municipios — coinciden dentro del 2%.

A confirmar: es el paso más atacable del manuscrito. Las dos fuentes no son independientes (ambas arrancan del parte policial), lo que sesga el estimador a la baja; por eso se presenta como piso y no como estimación puntual. Revisar que esa redacción sea suficiente y si la ventana de ± 1 h es defendible.

13. Validación contra mortalidad INEGI DATO

→ `06_validacion_inegi.py` · salidas `validacion_inegi_fiscalia.csv`,
`inegi_muertes_transporte.csv`

Contraste de conteos, no inferencia. Se agrupan los archivos EDR 2019–2024 y se filtra por año de **ocurrencia** (una muerte de 2023 puede registrarse en 2024) y por causa V01–V89. Dos cautelas que sí importan: `mun_ocurr` es donde ocurrió la muerte, muchas veces el hospital, por lo que el contraste se hace por grupo metropolitano; y en el archivo de 2019 las claves traen un tabulador pegado, así que sin limpiarlas ese año devuelve cero filas en silencio.

Hallazgo a reportar: Nuevo León codifica 1,817 de sus 1,864 muertes como V89 (tipo no especificado) mientras Tamaulipas distribuye, así que el paralelo V01–V79 no es utilizable y la definición de caso es V01–V89.